TAES · CIN-UFPE · 2026.2

De títulos de issues a requisitos com múltiplos agentes

Uma evolução multiagente de Paiva et al. (2026)

Tópicos Avançados em Software · Prof. Augusto Sampaio

Rafael [sobrenome] · Geo [nome completo] · Murilo Ventura · Felipe Torres

Centro de Informática UFPE
Universidade Federal de Pernambuco

CONTEXTO

Onde paramos: o artigo em uma página

150

títulos de issues

PyTorch, Flutter, Godot, Rust, Go

900

requisitos gerados

2 LLMs × 3 prompts

> 4/5

nota média

Qwen QwQ-32b como juiz

O que o artigo concluiu

1. **O prompt importa mais que o LLM.** o3-mini e DeepSeek R1 só diferem em Singularidade.
2. **Nenhum prompt vence em tudo.** Especialista sobe Verificabilidade e derruba Singularidade.
3. **Garbage in, garbage out.** Títulos vagos geram requisitos vagos, com qualquer modelo.

Um prompt só não otimiza os três critérios

DeepSeek R1 no artigo (média 1–5)

Prompt	Não amb.	Verific.	Singul.
Ingênuo	4,31	4,18	4,20
Few-shot	4,33	4,07	**4,69**
Especialista	4,42	**4,37**	**3,95**

Especialista: melhor Verificabilidade (4,37), pior Singularidade (3,95).
Few-shot: o inverso.

Por que isso acontece

$\rho = 0{,}30$

Verificabilidade × Singularidade

Singularidade é quase independente dos outros critérios.

Pedir detalhe (verificável) e foco (singular) no mesmo prompt gera conflito.

PROPOSTA

Nossa proposta e as perguntas de pesquisa

Hipótese: separar cada critério da ISO 29148 em um agente especialista, consolidar e revisar com um juiz que pode rejeitar gera requisitos melhores do que o melhor prompt único do artigo, sem o trade-off entre Verificabilidade e Singularidade.

QP-MA1 Qualidade

A arquitetura supera os 3 prompts do artigo nos três critérios?

QP-MA2 Trade-off

Ela mantém Singularidade alta sem perder Verificabilidade? A variância cai?

QP-MA3 Títulos vagos

Ela recupera os casos ruins do artigo (ex.: Godot)?

QP-MA4 Custo

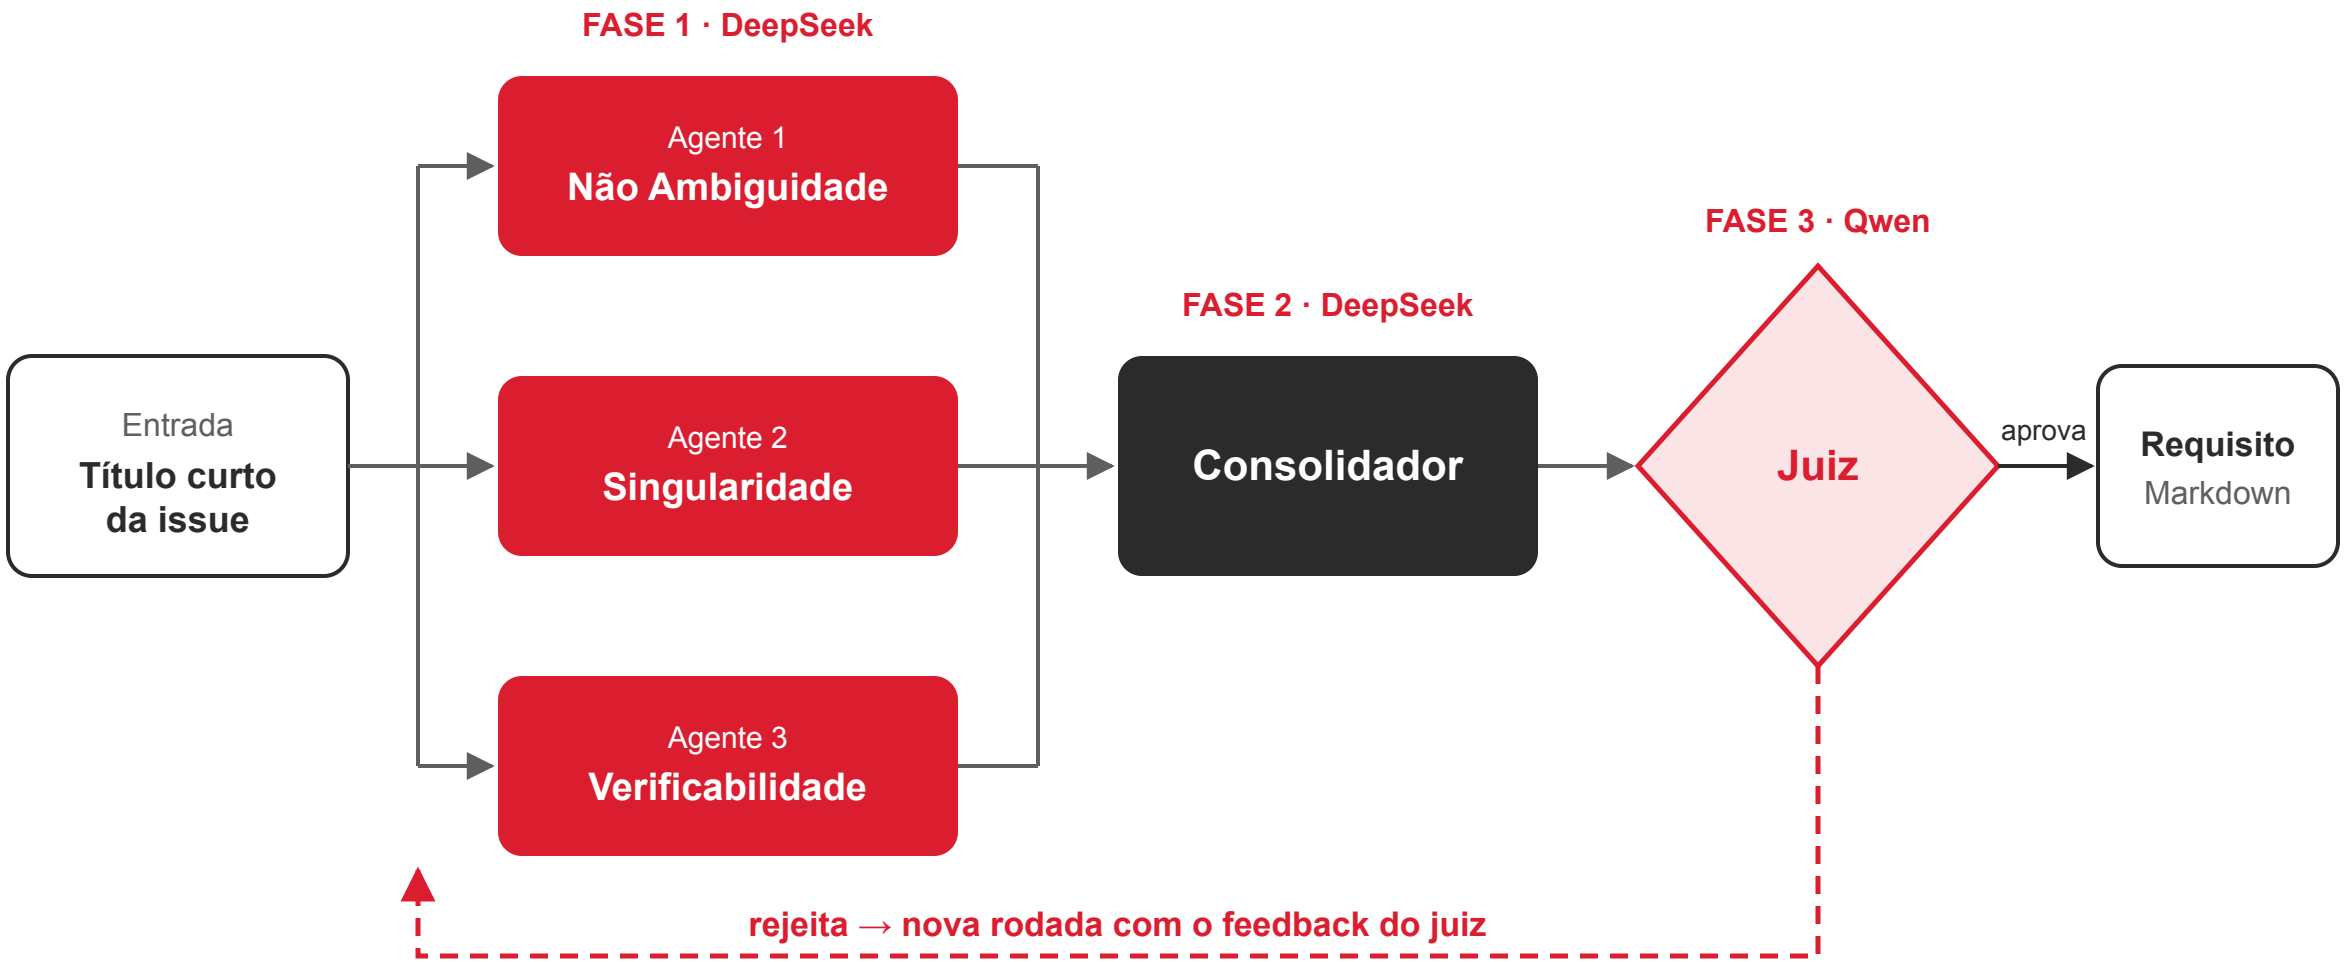
Quantas iterações, tokens e segundos custa cada requisito?

PARTE 1

A arquitetura multiagente

Três especialistas, um consolidador e um juiz

Do título ao requisito em três fases



O que cada agente faz

1 Não Ambiguidade
DEEPSEEK

Garante uma única interpretação: troca termos vagos por valores e nomes concretos.

2 Singularidade
DEEPSEEK

Garante uma única capacidade: corta escopo extra e separa o que não é central.

3 Verificabilidade
DEEPSEEK

Garante que dá para testar: explicita condição, critério e resultado esperado.

C Consolidador
DEEPSEEK

Funde as três propostas em um requisito, resolvendo conflitos entre elas.

J Juiz
QWEN

Pontua os 3 critérios (Likert 1–5); aprova ou devolve com justificativa.

Ideia central

Trocar a busca pelo prompt perfeito por papéis focados e autocorreção.

Como vamos comparar com o artigo

Mantido do artigo

- 150 issues (dataset público, Zenodo)
- 3 critérios da ISO/IEC/IEEE 29148
- Avaliador independente: Cohere command-a-plus (o Qwen guia o loop)
- Likert 1–5 + justificativa em JSON
- Testes não paramétricos (Wilcoxon pareado)

O que muda

- Prompt único → 5 agentes em 3 fases
- Ciclo de revisão: o juiz pode rejeitar
- 1 requisito por issue = 150 saídas
- Registro de iterações, tokens e tempo

Linhas de base

- DeepSeek v4.1 flash × Naive, Few-shot, Especialista, regerados nas 150 issues
- Mesmo modelo, mesmas issues: comparação pareada
- Valores do artigo só como referência

Como a execução diferiu da proposta

Ponto	Proposta	O que executamos
Fase 1	3 agentes especialistas, um por critério	**Principal (150 issues):** reaproveita 3 propostas já geradas (few-shot, expert, naive). **Ablação (30 issues):** os 3 especialistas reais
Gerador	DeepSeek	DeepSeek v4.1 flash (modelo mais novo e barato)
Juiz	Qwen avalia e aprova	Qwen 3.8-27b guia o loop; Cohere command-a-plus avalia (independente)
Linhas de base	Valores do artigo	Prompts regerados com o mesmo modelo e as mesmas issues
Custo	Tokens, tempo, chamadas	Medidos por requisito
Extra	—	Nota de fidelidade ao título da issue

Motivo: orçamento de API. Reaproveitar a Fase 1 evita ~3 chamadas por rodada; a ablação mede se a especialização muda o resultado.

O que vamos medir

Qualidade	Processo	Custo
Média e DP por critério	Iterações até aprovar	Tokens por requisito
Distribuição das notas (1–5)	Taxa de aprovação na 1ª rodada	Tempo por requisito
% de requisitos com nota ≤ 3	Motivos de rejeição do juiz	Chamadas de API por requisito
Notas por repositório		

Teste estatístico: Wilcoxon pareado (mesmas issues) entre o multiagente e cada prompt único.

PARTE 2

Resultados

DeepSeek v4.1 flash · 150 issues · avaliador independente

Visão geral: multiagente vs. melhor prompt

Não Ambiguidade

4,01 /5

Multiagente · DP 0,71

Melhor prompt único: **4,23** (Especialista)

Verificabilidade

4,29 /5

Multiagente · DP 0,93

Melhor prompt único: **4,61** (Especialista)

Singularidade

3,83 /5

Multiagente · DP 1,38

Melhor prompt único: **4,25** (Few-shot)

Mensagem principal: o multiagente tem a **maior média** (4,04 vs. 3,80 do melhor prompt, $p < 0,001$) e **49%** dos requisitos com os três critérios ≥ 4 (prompts únicos: 13–22%). Mas **não vence o melhor prompt em cada critério isolado**.

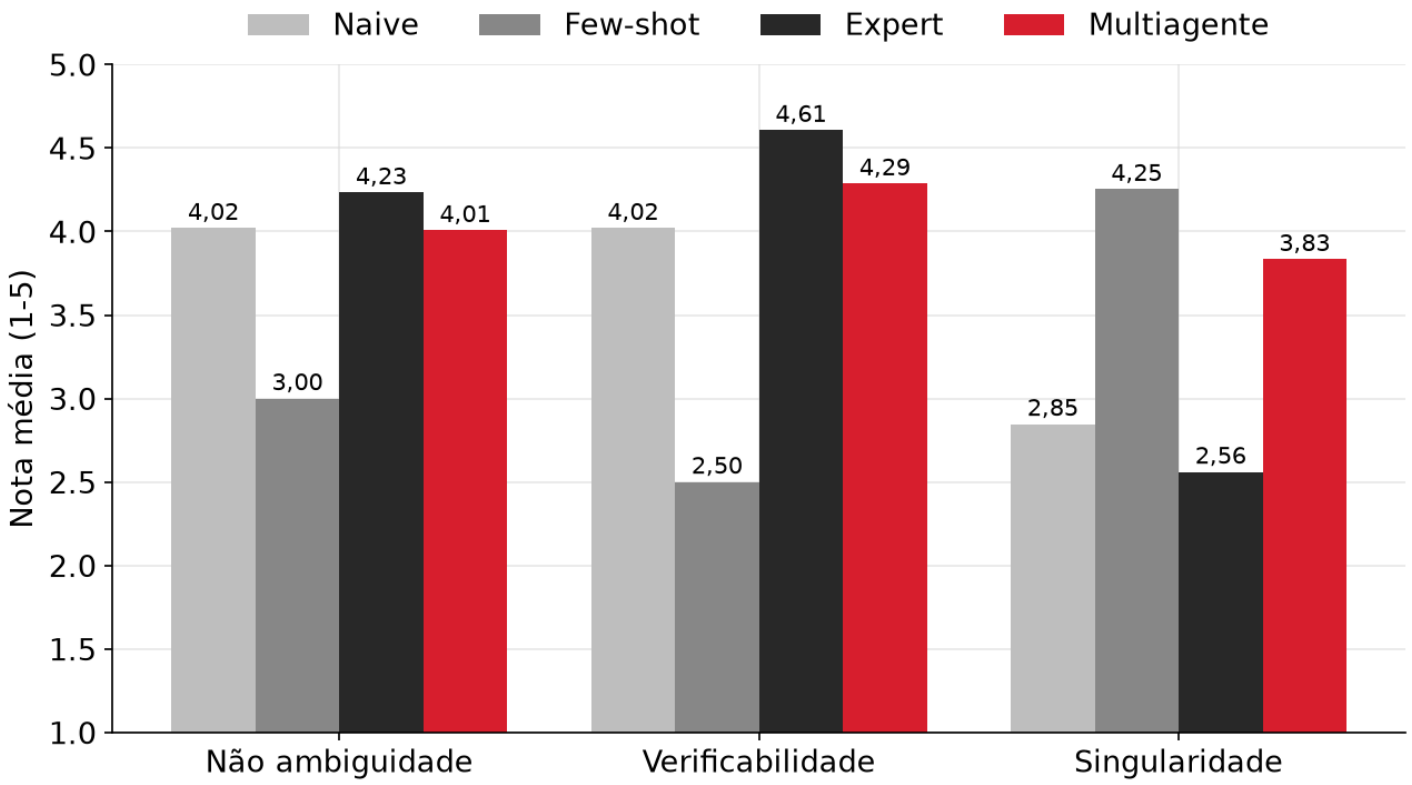
Comparação por estratégia

Estratégia (DeepSeek v4.1)	Não amb.	Verific.	Singul.	Média	3 critérios ≥ 4
Naive	4,02	4,02	2,85	3,63	22%
Few-shot	3,00	2,50	4,25	3,25	13%
Especialista	4,23	4,61	2,56	3,80	17%
Multiagente (nosso)	**4,01**	**4,29**	**3,83**	**4,04**	**49%**

150 issues, avaliador Cohere command-a-plus, mesmas issues em todas as linhas. Baselines regerados com o mesmo modelo (não são os valores do artigo). Multiagente = Fase 1 reaproveitada + consolidador + juiz Qwen.

Pareado vs. Especialista: média +0,24 ($p < 0,001$) · verificabilidade −0,32 · não ambiguidade −0,23 (ambos $p \leq 0,001$) · singularidade +1,27.

Nota média por critério

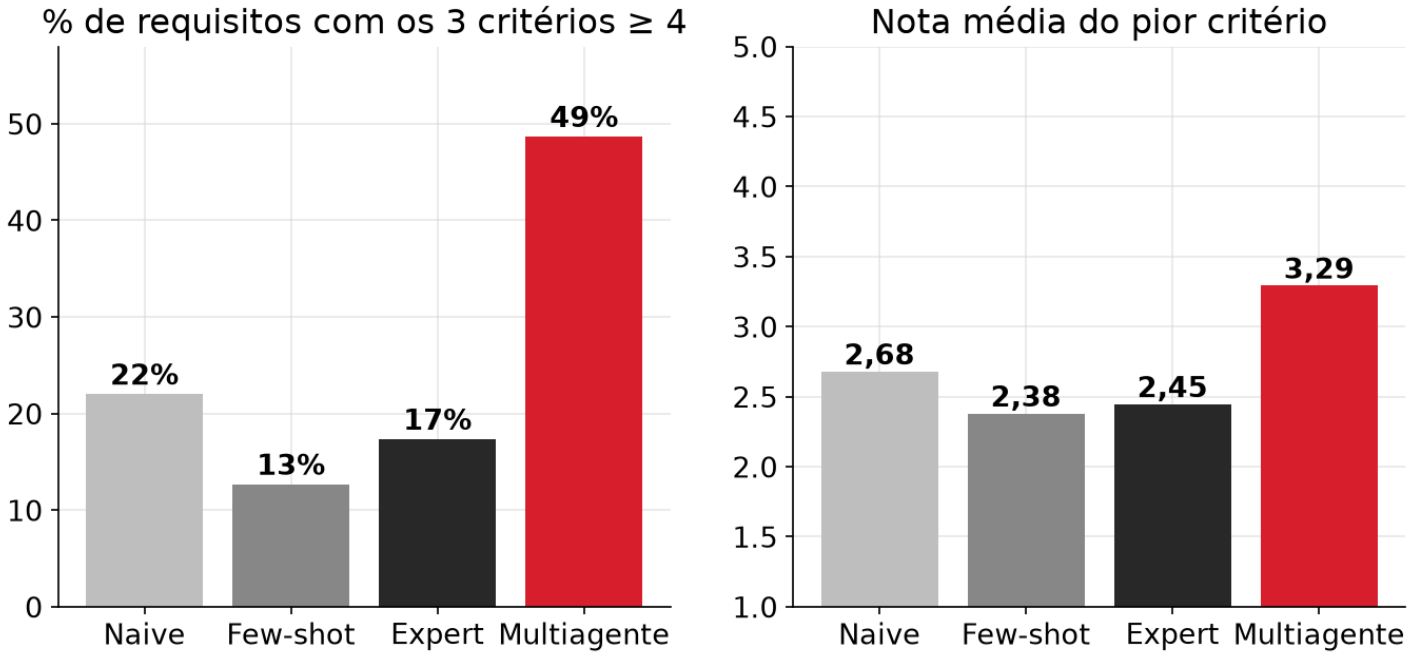


Leitura

Cada prompt único é forte em um critério e fraco em outro.

O multiagente fica **no meio-alto em todos**, sem o buraco de 2,5 a 3,0 dos prompts únicos.

O trade-off diminui

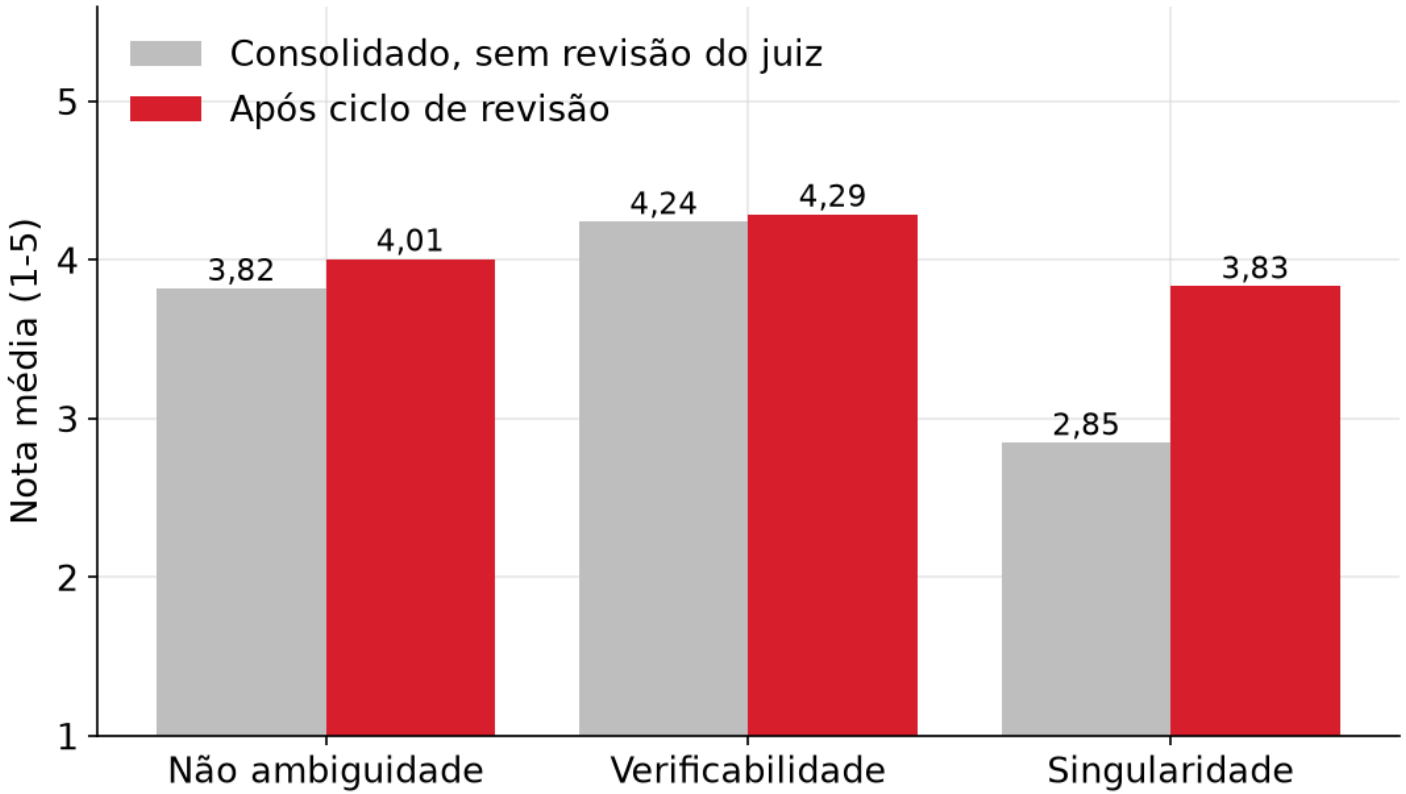


Leitura

49% dos requisitos passam de 4 nos três critérios ao mesmo tempo, contra 13–22% dos prompts únicos.

A variância de Singularidade **não** caiu (DP 1,38).

O ganho vem do ciclo de revisão

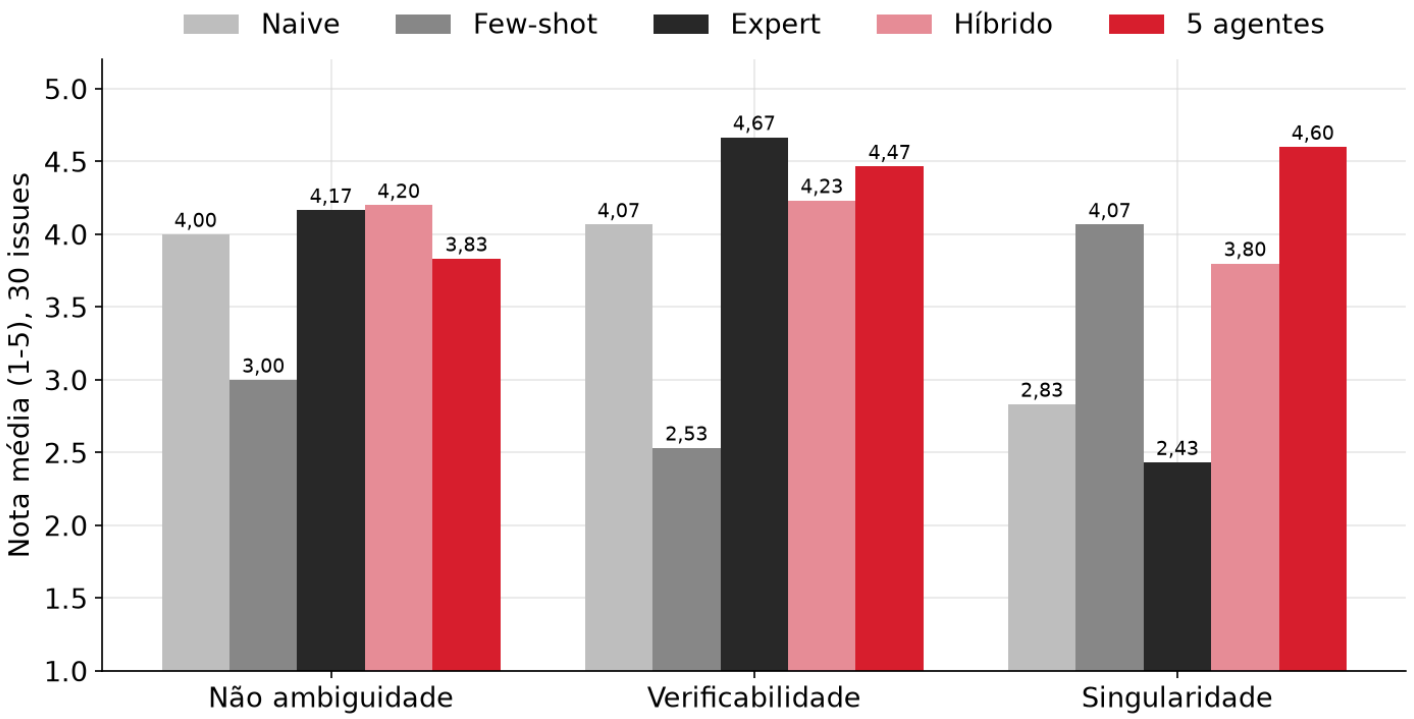


Leitura

Só consolidar as propostas **não** melhora a Singularidade.

É o feedback do juiz, em rodadas seguintes, que a leva de 2,85 para 3,83.

Com os 5 agentes reais (30 issues)



Leitura

Média **4,30** (híbrido 4,08); **67%** com os 3 critérios ≥ 4 (híbrido 57%).

Diferença para o híbrido **não significativa** (p = 0,18, n = 30). Contra o Especialista, +0,54 (p = 0,001).

Custo: ~13.2 mil tokens e 82 s por requisito.

Quanto custa a melhora

2,2
iterações médias
até o fim do ciclo

12%
aprovados na 1ª
sem nenhum retorno

7.6 mil
tokens/requisito
13.2 mil nos 5 agentes reais

41 s
tempo/requisito
82 s nos 5 agentes reais

Critério abaixo de 4 na 1ª rodada (juiz Qwen)

Singularidade **82%** · Não ambiguidade **64%** · Verificabilidade **61%**

47% das issues são aprovadas ao fim de 3 rodadas; as demais saem com a melhor versão. Custo do prompt único não medido (1 chamada por requisito).

Caso do artigo, refeito: “Implement Terrain”

DEEPSEEK V4.1 · PROMPT ESPECIALISTA

Requisito de 9 itens (heightmap, ruído procedural, LOD, edição com undo, APIs, formatos, testes, desempenho…) mais critérios de aceitação.

4 / 4 / 2

Não amb. / Verific. / Singul.

→

MULTIAGENTE · 3 ITERAÇÕES

“The system shall implement a heightmap-based terrain subsystem with configurable width, depth, height scale, resolution, and materials.”

4 / 3 / 2

Não amb. / Verific. / Singul. · mais curto e focado, mas Singularidade segue 2: título vago demais

Ameaças à validade

Juiz no ciclo ≠ avaliador final

Mitigado: o Qwen guia o loop e o Cohere avalia. Falta ainda amostra humana.

Só DeepSeek gerando

Medimos só com o DeepSeek v4.1 flash. Outros geradores ainda não foram testados na arquitetura.

Custo maior

Cerca de 5 chamadas e 7.6 mil tokens por requisito (13.2 mil nos 5 agentes reais).

Fase 1 híbrida e amostra pequena

Os 5 agentes reais só rodaram em 30 issues: a diferença para o híbrido não é significativa (p = 0,18).

FECHAMENTO

Conclusões e próximos passos

O que encontramos

Melhor média e menos trade-off: 4,04 vs. 3,80 do melhor prompt único ($p < 0,001$); 49% dos requisitos com os 3 critérios ≥ 4 (vs. 13–22%).

Mas não vence cada critério: o Especialista segue melhor em verificabilidade e não ambiguidade; o Few-shot, em singularidade. O ganho vem do ciclo de revisão do juiz.

5 agentes reais (30 issues): média 4,30 e 67% com os 3 critérios ≥ 4, a ~1,7× os tokens do híbrido. Ganho sobre o híbrido não significativo.

Próximos passos

RAG com contexto do repositório
README, issues relacionadas, código.

Agente de esclarecimento
Detecta título vago antes de gerar.

Outros geradores e juízes
Claude, Gemini, Llama; juiz de outra família.

Obrigado!

Perguntas?

Artigo: doi.org/10.1007/s00766-026-00462-z

Dataset: doi.org/10.5281/zenodo.15003691

Código: github.com/felipetmacedo/taes-multiagente-requisitos